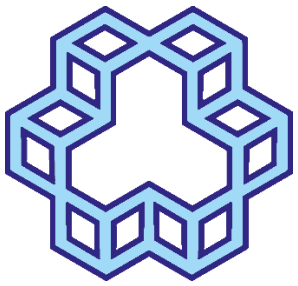

دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشکده مهندسی برق

درس یادگیری ماشین

استاد دکتر علیاری

سیدمحمدرضا حسینی

شماره دانشجویی: ۴۰۲۰۴۵۸۴

گرایش: سیستم های الکترونیک دیجیتال

مینی پروژه شماره ۴

Google Colab

Github

فهرست مطالب

سوال اول

Wumpus به‌عنوان یک عنصر ثابت در نظر گرفته شده است اما سایر بخش های امتیازی، مانند توانایی شلیک توسط عامل و امتیاز مرتبط با کشتن Wumpus، لحاظ شده است. الگوریتم DQN هم به‌طور کامل بررسی و تمامی سوالات مربوط به آن پاسخ داده شده است.

بخش آ

دنیای وومپوس یک مدل آموزشی کلاسیک در حوزه هوش مصنوعی است که توسط جان مک‌کارتی و ماروین مینسکی در دهه ۱۹۷۰ معرفی شد. این سناریو در یک محیط شبیه‌سازی شده ۴x۴ جریان دارد که اکتشافگر باید طلا را پیدا کرده و با موفقیت از محیط خارج شود. عناصر اصلی این محیط شامل اکتشافگر، طلا، وومپوس (موجود خطرناک)، حفره‌ها (موانع خطرناک) و خانه‌های خالی است. اکتشافگر توانایی حرکت به چهار جهت، تیراندازی برای کشتن وومپوس، برداشتن طلا و خروج از محیط را دارد. سیستم پاداش بر اساس کشف طلا و خروج ایمن یا شکست طراحی شده است.

برای حل این مسئله از روش‌های پیشرفته هوش مصنوعی مانند الگوریتم‌های جستجوی کلاسیک و یادگیری تقویتی (مانند Q-Learning و DQN) استفاده می‌شود. دنیای وومپوس به عنوان ابزار آموزشی، به درک اصول اساسی هوش مصنوعی و ارزیابی الگوریتم‌های نوین کمک می‌کند و به عنوان معیار آزمون و ارزیابی الگوریتم‌ها به کار می‌رود.

در ساخت محیط، عامل حداقل باید شش حرکت انجام دهد تا به طلا برسد و امتیازاتی بر اساس عملکرد خود دریافت کند. تنظیمات مختلف الگوریتم‌ها بر نتایج نهایی تاثیر می‌گذارد و هدف افزایش کارآمدی عملکرد عامل در محیط‌های دینامیک و چالشی است.

به دلیل پیچیدگی و مشکلات اجرای الگوریتمDQN ، تصمیم گرفتیم مکان اشیاء را در طول آموزش ثابت نگه داریم تا عامل بهتر یاد بگیرد.

برای حل این مسئله با الگوریتم‌های یادگیری تقویتی به دستگاه‌های قدرتمند و زمان زیادی نیاز است. به دلیل محدودیت‌ها، نسخه ساده‌تری را انتخاب کردیم که در آن مکان اشیاء ثابت بوده و حرکت نمی‌کنند. با هر اجرا، عامل به نقطه شروع بازگشته و وامپوس نیز مجدداً زنده می‌شود.

همان طور که گفتم مسئله Wumpus World یکی از نمونه‌های کلاسیک و تأثیرگذار در چالش‌های هوش مصنوعی است. این مسئله به‌طور دقیق نشان می‌دهد که چگونه می‌توان با استفاده از مجموعه‌ای از الگوریتم‌ها و تکنیک‌های مختلف، مشکلات پیچیده را حل کرد و عملکرد عامل‌ها را در محیط‌های دینامیک و چالش‌برانگیز بهبود بخشید. ارزیابی کدهای ارائه شده و توضیحات آن‌ها به درک عمیق‌تری از کاربرد این الگوریتم‌ها در دنیای Wumpus کمک می‌کند و امکان تحلیل و مقایسه نتایج حاصل از این پیاده‌سازی‌ها را فراهم می‌آورد.

در آغاز کار، با توجه به توضیح مسئله، به ساخت محیطی برای این چالش و تعریف قابلیت‌های لازم برای حرکت عامل در آن می‌پردازیم. محیط به صورت یک جدول چهار در چهار تعریف شده است که صفحه بازی ما را می‌سازد و دارای نقطه شروعی در مختصات (۰،۰) است. در این صفحه، علاوه بر عامل، اشیاء دیگری مانند طلا نیز وجود دارند که عامل در تلاش برای یافتن آن است و مکان آن توسط ما در نقطه (۳،۳) مشخص شده است که در شکل زیر قابل مشاهده است :

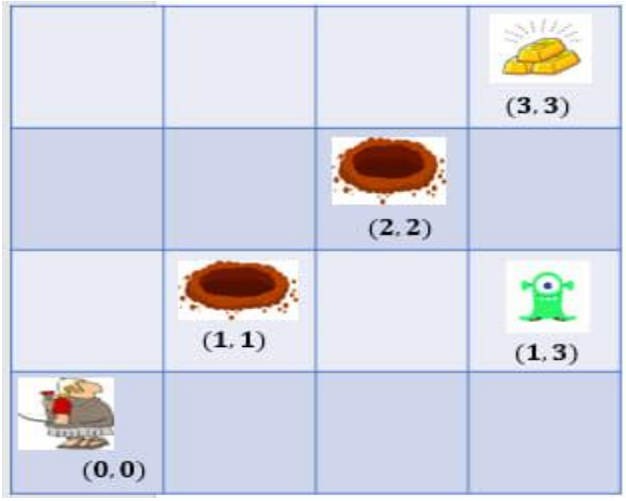

برای رسیدن به طلا، عامل باید حداقل شش حرکت انجام دهد. در ادامه، عامل برای هر حرکت که منجر به مرگ یا یافتن طلا نشود، امتیاز منفی (-۱) دریافت می‌کند و در بهترین حالت، با کشتن Wumpus و دریافت جایزه +۵۰ و همچنین یافتن طلا و دریافت جایزه +۱۰۰، امکان رسیدن به مجموع امتیازات ۱۴۵ وجود دارد. تغییرات در محیط و مکان اشیاء می‌تواند بر این حداکثر امتیاز تأثیر بگذارد. همچنین، تنظیم میزان Exploration الگوریتم به گونه‌ای که بتواند پس از مدتی به Exploitation بیشتری برسد، بر نتایج تأثیرگذار است و ممکن است عامل تنها به جای جستجوی حداکثر امتیاز، به یافتن طلا اکتفا کند که در این صورت حداکثر امتیاز قابل کسب +۹۵ خواهد بود. این دلیل همگرایی الگوریتم Q-learning به امتیاز +۹۵ است. در مراحل بعدی، با تغییر نحوه کاهش نرخ Exploration، این جنبه بیشتر مورد بررسی قرار می‌گیرد و انتظار می‌رود که با تنظیم مناسب، عامل بتواند به بیشترین امتیاز ممکن دست یابد، همانند آنچه در الگوریتم DQN رخ می‌دهد.

موارد امتیازی هم لحاظ شدند.

حال به سراغ کد نویسی و توضیح کد ها میرویم : (پیاده سازی و شرح نحوه تعریف محیط و قابلیت های عامل)

```python
class GridEnvironment:
    def __init__(self):
        self.grid_size = 4
        self.grid = np.zeros((self.grid_size, se
        self.agent_position = [0, 0]
        self.gold_position = [3, 3]
        self.pits = [[1, 1], [2, 2]]
        self.wumpus_position = [1, 3]
        self.wumpus_alive = True
        self.arrow_available = True

        # Setting up the grid
        self.grid[self.gold_position[0], self.go
        for pit in self.pits:
            self.grid[pit[0], pit[1]] = -1
        self.grid[self.wumpus_position[0], self.

    def reset(self):
        # Reset the positions and statuses
```

کد بالا یک کلاس به نام GridEnvironment ایجاد می‌کند که محیط شبیه‌سازی شده بازی Wumpus World را فراهم می‌کند. این محیط شامل یک شبکه ۴x۴ با خانه‌های خالی است و موقعیت‌های اولیه عناصر مختلف مانند عامل، طلا، چاه‌ها و وامپوس را تعیین می‌کند. همچنین، وضعیت اولیه وامپوس و تیر به True تنظیم می‌شوند.

```python
def reset(self):
    # Reset the positions and statuses
    self.agent_position = [0, 0]
    self.wumpus_position = [1, 3]
    self.wumpus_alive = True
    self.arrow_available = True
    return tuple(self.agent_position)

def step(self, action):
    reward = -1  # Movement penalty
    done = False

    # Move the agent based on the action
    if action == 'up':
        self.agent_position[0] = max(0, self.agent_position[0] - 1)
    elif action == 'down':
        self.agent_position[0] = min(self.grid_size - 1, self.agent_position[0] + 1)
    elif action == 'left':
        self.agent_position[1] = max(0, self.agent_position[1] - 1)
    elif action == 'right':
        self.agent_position[1] = min(self.grid_size - 1, self.agent_position[1] + 1)
    elif action == 'shoot_up' and self.arrow_available:
        # Shoot the arrow upwards
        if self.wumpus_position[0] < self.agent_position[0]:
            reward = 50
            self.wumpus_alive = False
        self.arrow_available = False
    elif action == 'shoot_down' and self.arrow_available:
        # Shoot the arrow downwards
        if self.wumpus_position[0] > self.agent_position[0]:
            reward = 50
            self.wumpus_alive = False
        self.arrow_available = False
    elif action == 'shoot_left' and self.arrow_available:
        # Shoot the arrow to the left
        if self.wumpus_position[1] < self.agent_position[1]:
            reward = 50
```

```
            if self.wumpus_position[0] < self.agent_position[0]:
                reward = 50
                self.wumpus_alive = False
            self.arrow_available = False
        elif action == 'shoot_down' and self.arrow_available:
            # Shoot the arrow downwards
            if self.wumpus_position[0] > self.agent_position[0]:
                reward = 50
                self.wumpus_alive = False
            self.arrow_available = False
        elif action == 'shoot_left' and self.arrow_available:
            # Shoot the arrow to the left
            if self.wumpus_position[1] < self.agent_position[1]:
                reward = 50
                self.wumpus_alive = False
            self.arrow_available = False
        elif action == 'shoot_right' and self.arrow_available:
            # Shoot the arrow to the right
            if self.wumpus_position[1] > self.agent_position[1]:
                reward = 50
                self.wumpus_alive = False
            self.arrow_available = False

        # Check if the game has ended
        if self.agent_position == self.gold_position:
            reward = 100  # Reward for finding the gold
            done = True
        elif self.agent_position in self.pits:
            reward = -1000                    # Penalty for falling into a pit
            done = True
        elif self.agent_position == self.wumpus_position and self.wumpus_alive:
            reward = -1000                    # Penalty for encountering a live Wumpus
            done = True

        return tuple(self.agent_position), reward, done

    def get_possible_actions(self):
        # Get a list of possible actions
        return ['up', 'down', 'left', 'right', 'shoot_up', 'shoot_down', 'shoot_left', 'shoot_right']
```

سه تابع در این کلاس به شبیه‌سازی محیط Wumpus World کمک می‌کنند:

۱. **تابع reset** : برای بازنشانی محیط به حالت اولیه، بازگرداندن عامل به نقطه شروع و تنظیم مجدد وضعیت وامپوس و تیر استفاده می‌شود.

۲. **تابع step** : این تابع عملیات انجام شده در محیط را ارزیابی می‌کند. هر حرکت یک جریمه -۱ دارد. بر اساس عمل انتخاب شده (حرکت به جهات مختلف یا شلیک تیر)، موقعیت عامل تغییر می‌کند و وضعیت وامپوس و تیر به‌روزرسانی می‌شود. رسیدن به طلا ۱۰۰ امتیاز، افتادن در چاه یا برخورد با وامپوس زنده -۱۰۰۰ امتیاز، و کشتن وامپوس ۵۰ امتیاز دارد.

۳. **تابع get_possible_actions** : این تابع لیستی از عملیات‌های ممکن را بازمی‌گرداند:

['up', 'down', 'left' 'right', 'shoot_up', 'shoot_down', 'shoot_left', 'shoot_right'].

این توابع برای مدیریت و ارزیابی عملکرد عامل در محیط Wumpus World طراحی شده‌اند و پایه‌ای برای پیاده‌سازی الگوریتم‌های یادگیری تقویتی هستند.

دو الگوریتم را بررسی میکنیم. Q learning و DQN که در ادامه به آن ها می پردازیم.

الگوریتم Q-learning

روش Q-learning یکی از تکنیک‌های یادگیری تقویتی است که به‌طور گسترده برای حل مسائل پیچیده در حوزه هوش مصنوعی استفاده می‌شود. این روش به‌ویژه در مسائلی کاربرد دارد که در آن‌ها یک عامل باید از طریق تعامل با محیط، استراتژی بهینه‌ای برای رسیدن به هدف بیابد . Q-learning یک روش یادگیری بدون مدل است که به عامل امکان می‌دهد بدون داشتن اطلاعات قبلی از محیط، یک سیاست برای رسیدن به هدف یاد بگیرد. این روش بر اساس یادگیری مقادیر عمل-وضعیت (state-action values)یا Q-values عمل می‌کند. Q-value نشان‌دهنده امتیاز پیش‌بینی‌شده‌ای است که عامل می‌تواند با انجام یک عمل خاص در یک وضعیت خاص انتظار داشته باشد. هدف اصلی در Q-learning، به‌روزرسانی مقدار Q برای هر جفت وضعیت-عمل است تا Q-value به مقدار واقعی نزدیک شود. کلاس Qlearning را به صورت زیر تعریف می کنیم.

```python
class QLearningAgent:
    def __init__(self, env, learning_rate=0.1, discount_factor=0.9, exploration_rate=1.0, exploration_decay=0.995):
        self.env = env
        self.q_table = {}                           # Initialize the Q-table as an empty dictionary
        self.learning_rate = learning_rate          # Learning rate for Q-learning updates
        self.discount_factor = discount_factor      # Discount factor for future rewards
        self.exploration_rate = exploration_rate    # Initial exploration rate for epsilon-greedy policy
        self.exploration_decay = exploration_decay  # Decay rate for exploration rate

    def get_q_value(self, state, action):
        # Retrieve the Q-value for a given state-action pair from the Q-table, default to 0.0 if not found
        return self.q_table.get((state, action), 0.0)

    def update_q_value(self, state, action, reward, next_state):
        # Get the best next action based on the current Q-values
        best_next_action = max(self.env.get_possible_actions(), key=lambda a: self.get_q_value(next_state, a))

        # Calculate the target Q-value using the reward and the discounted Q-value of the best next action
        td_target = reward + self.discount_factor * self.get_q_value(next_state, best_next_action)

        # Calculate the temporal difference error
        td_error = td_target - self.get_q_value(state, action)

        # Update the Q-value for the state-action pair using the learning rate
        new_q_value = self.get_q_value(state, action) + self.learning_rate * td_error

        # Store the updated Q-value in the Q-table
        self.q_table[(state, action)] = new_q_value

    def choose_action(self, state):
        # Choose an action using epsilon-greedy policy
        if random.uniform(0, 1) < self.exploration_rate:
            return random.choice(self.env.get_possible_actions())     # Explore: choose a random action
        else:
            return max(self.env.get_possible_actions(), key=lambda a: self.get_q_value(state, a))  # Exploit: choose the best action

    def train(self, episodes):
        total_rewards = []
        for episode in range(episodes):
            state = self.env.reset()
            total_reward = 0
            done = False
            while not done:
                action = self.choose_action(state)
                next_state, reward, done = self.env.step(action)
                self.update_q_value(state, action, reward, next_state)
                state = next_state
                total_reward += reward
            total_rewards.append(total_reward)
```

```
                self.update_q_value(state, action, reward, next_state)
                state = next_state
                total_reward += reward
            total_rewards.append(total_reward)
            self.exploration_rate *= self.exploration_decay  # Decay the exploration rate
        return total_rewards

def plot_rewards(total_rewards, cumulative_rewards, mean_rewards, title, filename):
    fig, axs = plt.subplots(3, 1, figsize=(10, 7))

    # Plot total rewards per episode
    axs[0].plot(total_rewards, label='Total Reward', color='purple', linestyle='-', linewidth=0.8)
    axs[0].set_xlabel('Episode')
    axs[0].set_ylabel('Total Reward')
    axs[0].set_title(f'Total Reward per Episode ({title})')
    axs[0].legend()
    axs[0].grid(True)
    axs[0].annotate(f'Last value: {total_rewards[-1]}', xy=(len(total_rewards)-1, total_rewards[-1]),
                    xytext=(len(total_rewards)-1, total_rewards[-1]), textcoords='data',
                    arrowprops=dict(arrowstyle='->', color='purple'))

    # Plot cumulative rewards
    axs[1].plot(cumulative_rewards, label='Cumulative Reward', color='orange', linestyle='-', linewidth=0.8)
    axs[1].set_xlabel('Episode')
    axs[1].set_ylabel('Cumulative Reward')
    axs[1].set_title(f'Cumulative Reward per Episode ({title})')
    axs[1].legend()
    axs[1].grid(True)
    axs[1].annotate(f'Last value: {cumulative_rewards[-1]}', xy=(len(cumulative_rewards)-1, cumulative_rewards[-1]),
                    xytext=(len(cumulative_rewards)-1, cumulative_rewards[-1]), textcoords='data',
                    arrowprops=dict(arrowstyle='->', color='orange'))

    # Plot mean rewards
    axs[2].plot(mean_rewards, label='Mean Reward', color='green', linestyle='-', linewidth=0.8)
    axs[2].set_xlabel('Episode')
    axs[2].set_ylabel('Mean Reward')
    axs[2].set_title(f'Mean Reward per Episode ({title})')
    axs[2].legend()
    axs[2].grid(True)
    axs[2].annotate(f'Last value: {mean_rewards[-1]}', xy=(len(mean_rewards)-1, mean_rewards[-1]),
                    xytext=(len(mean_rewards)-1, mean_rewards[-1]), textcoords='data',
                    arrowprops=dict(arrowstyle='->', color='red'))

    plt.tight_layout()
    plt.savefig(filename)
    plt.show()
```

کلاس QLearningAgent را تعریف می کنیم که شامل متد ها و اتربیوت هایی است که به اختصار توضیح می دهم.

- هدف: پیاده‌سازی الگوریتم Q-learning برای آموزش یک عامل در محیط‌های مختلف، از جمله Wumpus World.

توابع و ویژگی‌ها:

- __init__: این تابع سازنده پارامترهایی مانند محیط (env)، نرخ یادگیری (learning_rate)، عامل تخفیف (discount_factor)، نرخ اکتشاف اولیه (exploration_rate) و نرخ کاهش اکتشاف (exploration_decay) را می‌گیرد. جدول Q به عنوان یک دیکشنری خالی شروع می‌شود تا مقادیر Q جفت‌های حالت-عمل را ذخیره کند.

- get_q_value: مقدار Q مربوط به یک جفت حالت-عمل را بازمی‌گرداند. اگر جفت حالت-عمل در جدول Q موجود نباشد، مقدار پیش‌فرض ۰٫۰ بازگردانده می‌شود.

- update_q_value: این متد برای به‌روزرسانی مقدار Q یک جفت حالت-عمل استفاده می‌شود. بهترین عمل برای حالت بعدی بر اساس مقادیر Q فعلی محاسبه و مقدار Q با استفاده از پاداش و مقدار Q تخفیف‌یافته به‌روزرسانی می‌شود.

- choose_action: از سیاست ε-greedy استفاده می‌کند، به این معنا که با احتمال ε عمل تصادفی و با احتمال ۱-ε بهترین عمل انتخاب می‌شود.

- train: عامل را از طریق تعدادی اپیزود آموزش می‌دهد. محیط در هر اپیزود بازنشانی می‌شود و عامل با انتخاب و اجرای عمل‌ها یاد می‌گیرد. مجموع پاداش‌ها در هر اپیزود جمع‌آوری شده و نرخ اکتشاف به مرور کاهش می‌یابد.

نمایش نتایج:

- تابع plot_rewards: سه نمودار را برای نمایش عملکرد عامل ترسیم می‌کند:

- نمودار مجموع پاداش‌ها: پاداش کسب‌شده در هر اپیزود را نمایش می‌دهد.

- نمودار پاداش‌های تجمعی: مجموع پاداش‌ها را در طول اپیزودها نشان می‌دهد.

- نمودار میانگین پاداش‌ها: میانگین پاداش‌ها را در طول اپیزودها ترسیم می‌کند.

نکات :

- عامل با نرخ کاهش اکتشاف سریع‌تر (۰,۹۹۵) تنظیم شده تا به سرعت به سمت سیاست‌های بهینه همگرا شود.

- آموزش عامل برای ۱۰۰۰ اپیزود انجام می‌شود که می‌تواند تغییر کند اما بنا به خواسته صورت مسئله این مقدار فرض کردم.

حال مقدار دهی اولیه را انجام می دهیم :

```python
# Initialize environment and agent
env = GridEnvironment()
agent = QLearningAgent(env, exploration_decay=0.995)

# Train agent
episodes = 1000
total_rewards = agent.train(episodes)

# Calculate cumulative rewards and mean rewards
cumulative_rewards = np.cumsum(total_rewards)
mean_rewards = np.cumsum(total_rewards) / np.arange(1, len(total_rewards) + 1)

# Plot the results
plot_rewards(total_rewards, cumulative_rewards, mean_rewards, "QLearning Agent Training", "qlearning_training_rewards.png")

# Print detailed statistics
print("\n╔═══════════════════════════════╗")
print("║            Summary            ║")
print("╠═══════════════════════════════╣")
print(f"║ Number of Deaths : {sum(r < 0 for r in total_rewards):>10} ║")
print(f"║ Total Rewards    : {sum(total_rewards):>10} ║")
print(f"║ Highest Reward   : {max(total_rewards):>10} ║")
print(f"║ Lowest Reward    : {min(total_rewards):>10} ║")
print(f"║ Accuracy         : {sum(r > 0 for r in total_rewards) / len(total_rewards) * 100:>9.2f}% ║")
print("╚═══════════════════════════════╝\n")

# Q-learning results for comparison part:
Qtotal_rewards = total_rewards
Qcumulative_rewards = cumulative_rewards
Qmean_rewards = mean_rewards
```

گام های زیر به طور خلاصه طی شده است :

- ایجاد محیط GridEnvironment و عامل Q-learning.
- آموزش عامل و به‌روزرسانی مقادیر Q در طول اپیزودها.
- ذخیره نتایج پاداش‌ها در متغیر total_rewards.

با ران کردن کد، خروجی ای به صورت شکل صفحه بعد به دست می آید :

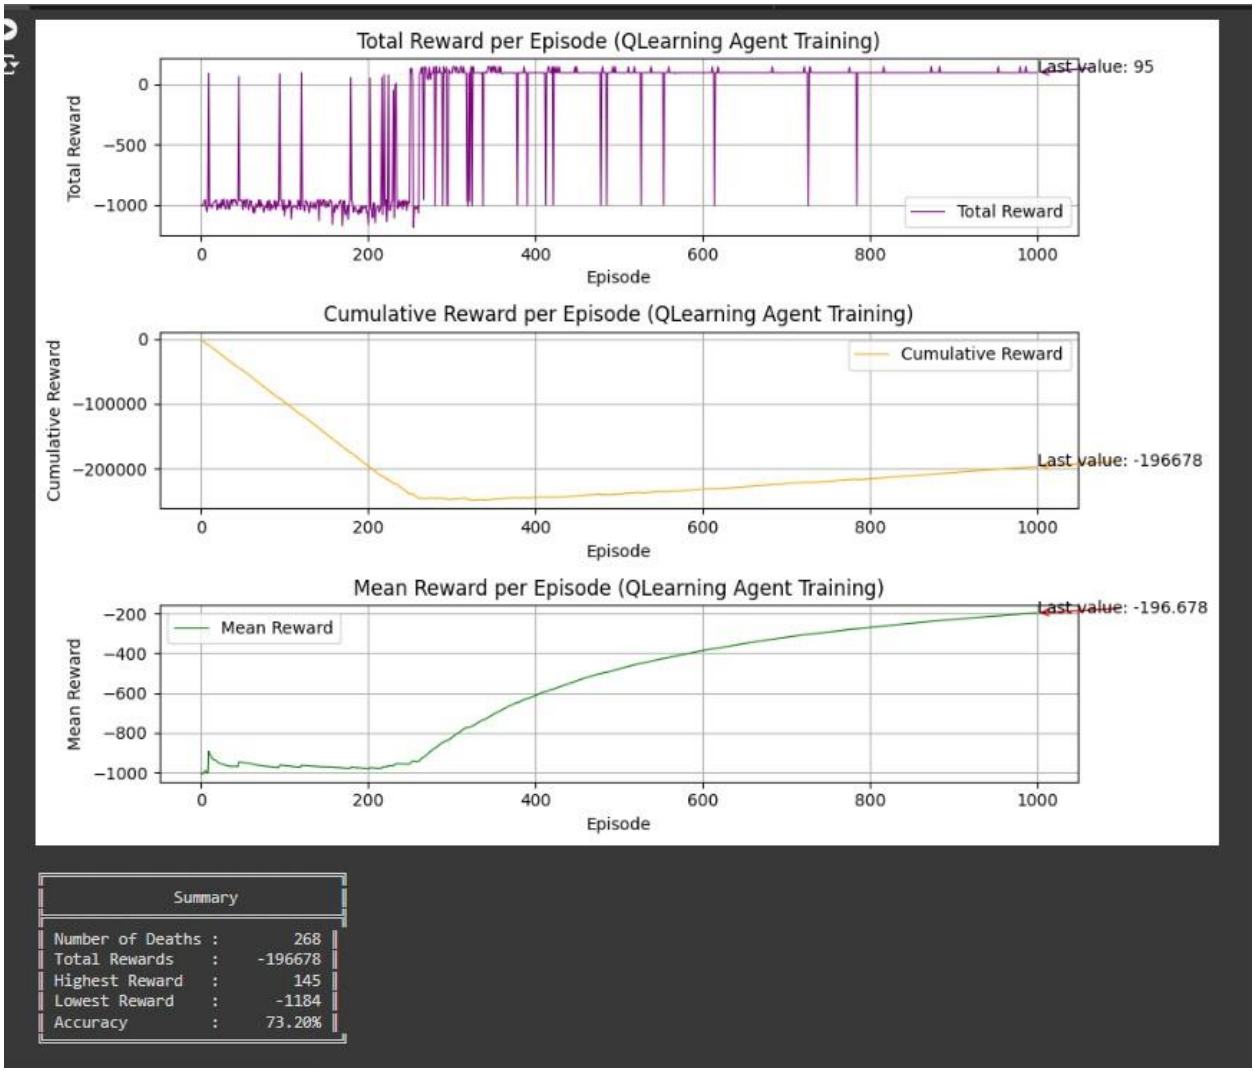

در بررسی انجام شده، از ۱۰۰۰ اپیزود، عامل ۲۶۸ بار کشته شده و بالاترین امتیاز کسب‌شده ۱۴۵ بوده است. کمترین امتیاز به میزان منفی ۱۱۸۴ است. حدود ۷۳ درصد اپیزودها با موفقیت و بدون کشته شدن به پایان رسیده‌اند. با این حال، معیار دقت به تنهایی نمی‌تواند عملکرد مدل را به خوبی نشان دهد، زیرا پس از مدتی، عامل یاد می‌گیرد و بهتر است عملکرد از آن نقطه به بعد ارزیابی شود. نکته مهم این است که روند صعودی نمودار میانگین امتیازها (نمودار سوم) همچنان ادامه دارد و هنوز به همگرایی نرسیده است، بنابراین نمایش ریوارد منفی به عنوان آخرین مقدار چندان معتبر نیست. بنابراین قصد داریم الگوریتم را برای ۱۰۰۰۰۰ اپیزود نیز بررسی کنیم.

نتایج به صورت صفحه بعد است :

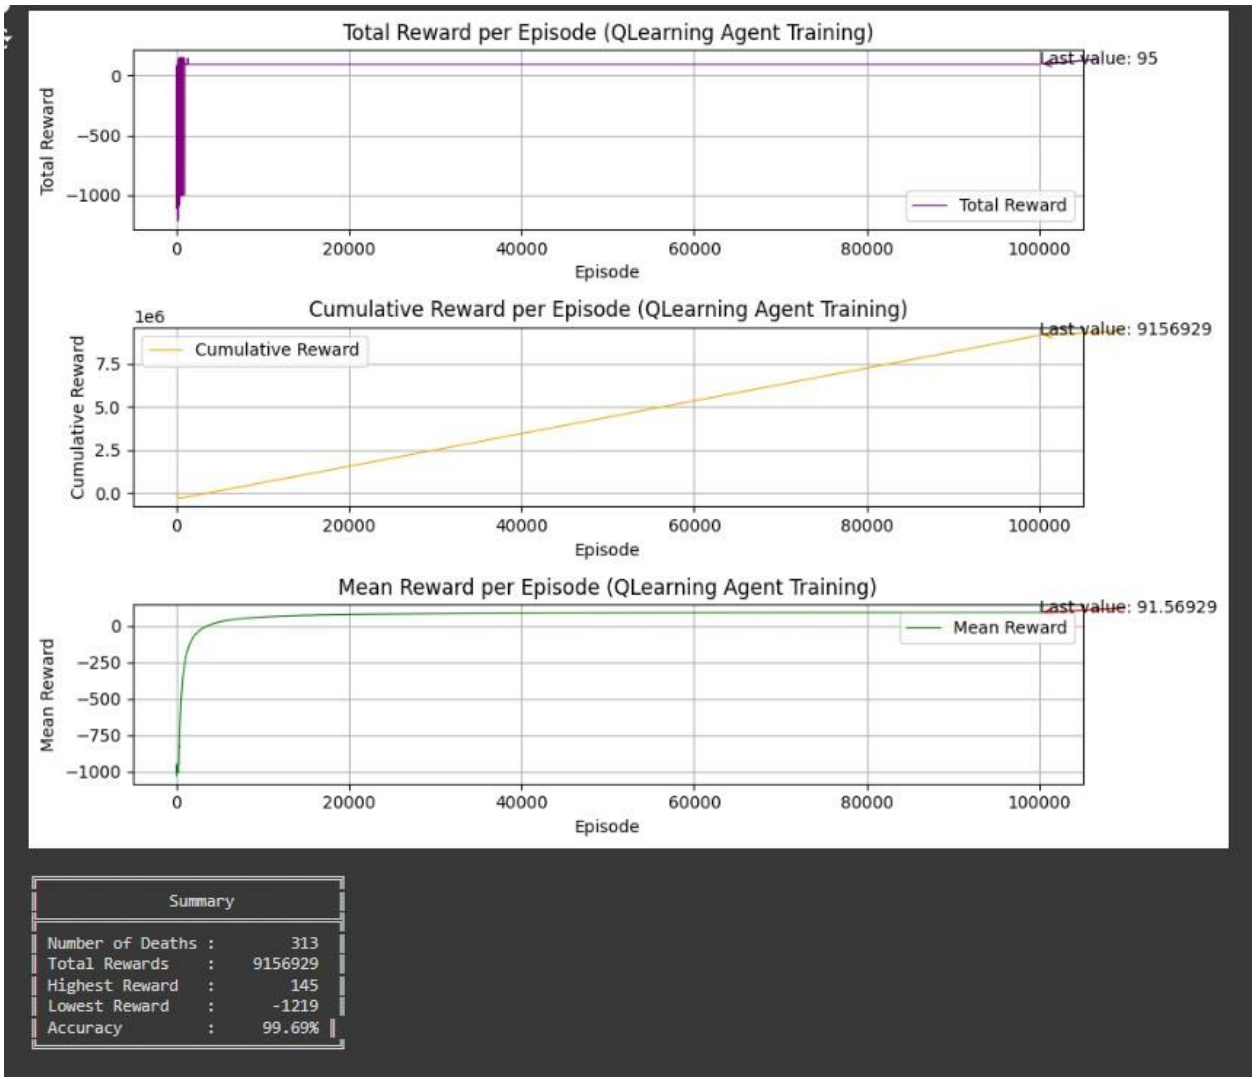

در این حالت مشاهده می شود که نمودار میانگین امتیازها تقریبا ثابت شده است و بنابراین همگرا شده است.

همچنین می بینیم که نمودار سوم به مقداری نزدیک ۹۱ همگرا شده است که بهترین سیاستی است که Agent یادگرفته است.

الگوریتمDQN

Deep Q-Networks (DQN) توسط محققان DeepMind برای غلبه بر محدودیت‌های Q-learning در محیط‌های پیچیده و بزرگ توسعه یافته است. برخلاف Q-learning که از جدول Q استفاده می‌کند، DQNاز شبکه‌های عصبی عمیق برای ذخیره مقادیر Q-value بهره می‌برد، که این امکان را می‌دهد سیاست‌های پیچیده‌تری را یاد بگیرد.

مزایا:

- عملکرد بهتر در محیط‌های با فضای حالت وسیع
- توانایی یادگیری توابع Q-value پیچیده و غیرخطی
- استفاده از تکنیک تجربه تکراری برای کاهش وابستگی به ترتیب تجربیات و بهبود کارایی یادگیری

معایب:

- نیاز به قدرت محاسباتی بالا
- پیچیدگی در تنظیم هایپرپارامترها
- عدم تضمین همگرایی مطمئن

در مسئله Wumpus World ، DQN برای تخمین مقادیر Q-value استفاده می‌شود. این الگوریتم با شبکه عصبی عمیق و تکنیک حافظه تجربه تکراری کار می‌کند. تجربیات عامل در حافظه ذخیره شده و به‌طور تصادفی برای به‌روزرسانی وزن‌های شبکه استفاده می‌شوند. حافظه بازپخش شامل وضعیت فعلی، عمل انجام شده، پاداش دریافتی، وضعیت بعدی و شاخص پایان اپیزود است و به پایداری و کارایی یادگیری کمک می‌کند DQN .به‌ویژه در بازی‌های ویدیویی و محیط‌های پیچیده کاربرد دارد.

شکل زیر مقایسه ای بین الگوریتم DQN و الگوریتم Q learning است.

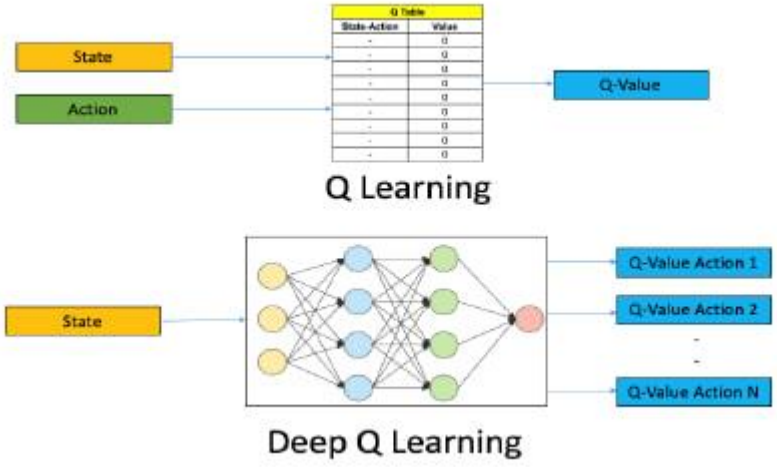

تعاریف اولیه مانند مجموعه‌های Reward Set و Action Set، ایجاد Environment، و قابلیت‌های Agent همانند قبل تعریف شده‌اند. در این بخش، تنها به بررسی بخش‌های جدید اضافه شده در این الگوریتم پرداخته می‌شود (کلاس ReplayMemory)

```python
class ReplayMemory:
    def __init__(self, capacity, state_shape):
        self.capacity = capacity
        self.states = np.zeros((capacity,) + state_shape, dtype=np.float32)
        self.actions = np.zeros(capacity, dtype=np.int32)
        self.rewards = np.zeros(capacity, dtype=np.float32)
        self.next_states = np.zeros((capacity,) + state_shape, dtype=np.float32)
        self.dones = np.zeros(capacity, dtype=np.bool_)
        self.index = 0
        self.current_size = 0

    def store(self, state, action, reward, next_state, done):
        self.states[self.index] = state
        self.actions[self.index] = action
        self.rewards[self.index] = reward
        self.next_states[self.index] = next_state
        self.dones[self.index] = done
        self.index = (self.index + 1) % self.capacity
        self.current_size = min(self.current_size + 1, self.capacity)

    def sample(self, batch_size):
        indices = np.random.choice(self.current_size, batch_size, replace=False)
        return (self.states[indices], self.actions[indices], self.rewards[indices],
                self.next_states[indices], self.dones[indices])
```

کلاس ReplayMemory برای *ذخیره و مدیریت تجربیات عامل در الگوریتم‌های یادگیری تقویتی مانند DQN طراحی شده است*. این کلاس با ذخیره تجربیات و انتخاب تصادفی آن‌ها برای یادگیری، پایداری و کارایی یادگیری سیاست‌های پیچیده را بهبود می‌بخشد. سه تابع این کلاس (متد) را به اختصار توضیح میدهم.

- **__init__ سازنده :**ظرفیت حافظه و آرایه‌هایی برای ذخیره وضعیت‌ها، اعمال، پاداش‌ها، وضعیت‌های بعدی و شاخص پایان اپیزود را تعریف می‌کن.
- **store ذخیره تجربه :**تجربه جدید را ذخیره کرده و موقعیت فعلی و تعداد تجربیات را به‌روزرسانی می‌کند
- **sample انتخاب تصادفی تجربیات :**یک دسته تصادفی از تجربیات را برای یادگیری انتخاب می‌کند.

در ادامه از کد های زیر استفاده میکنیم که در واقع اومدیم کلاس DQNAgent را تعریف کردیم.

```
class DQNAgent:
    def __init__(self, learning_rate, gamma, state_shape, num_actions, batch_size,
                 epsilon_initial=1.0, epsilon_decay=0.995, epsilon_final=0.05,
                 replay_buffer_capacity=1000):
        self.learning_rate = learning_rate
        self.gamma = gamma
        self.num_actions = num_actions
        self.batch_size = batch_size
        self.epsilon = epsilon_initial
        self.epsilon_decay = epsilon_decay
        self.epsilon_final = epsilon_final
        self.buffer = ReplayMemory(replay_buffer_capacity, state_shape)
        self.q_network = self._build_model(state_shape, num_actions)
        self.target_network = self._build_model(state_shape, num_actions)
        self.update_target_network()

    def _build_model(self, state_shape, num_actions):
        model = keras.Sequential([
            keras.layers.Dense(128, activation='relu', input_shape=state_shape),
            keras.layers.Dense(128, activation='relu'),
            keras.layers.Dense(num_actions, activation=None)
        ])
        model.compile(optimizer=keras.optimizers.Adam(learning_rate=self.learning_rate),
                      loss=Huber())
        return model

    def update_target_network(self):
        self.target_network.set_weights(self.q_network.get_weights())

    def select_action(self, state):
        if np.random.rand() < self.epsilon:
            action = np.random.randint(self.num_actions)
        else:
            q_values = self.q_network.predict(state[np.newaxis])
            action = np.argmax(q_values[0])
        return action

    def train(self, env, episodes):
        total_rewards, cumulative_rewards = [], []
        for episode in range(episodes):
            state = env.reset()
            done, total_reward = False, 0
```

Connected to Python 3.G

```
        mean_rewards = np.cumsum(total_rewards) / (np.arange(len(total_rewards)) + 1)
        self.save_rewards_data(total_rewards, cumulative_rewards, mean_rewards)

        # Print detailed statistics
        print("\n╔═══════════════════════════════════╗")
        print("║              Summary              ║")
        print("╠═══════════════════════════════════╣")
        print(f"║ Number of Deaths : {sum(r < 0 for r in total_rewards)} ║")
        print(f"║ Total Rewards    : {sum(total_rewards)} ║")
        print(f"║ Highest Reward   : {max(total_rewards)} ║")
        print(f"║ Lowest Reward    : {min(total_rewards)} ║")
        print(f"║ Accuracy         : {sum(r > 0 for r in total_rewards) / len(total_rewards) * 100:.2f}% ║")
        print("╚═══════════════════════════════════╝\n")


        return total_rewards, cumulative_rewards, mean_rewards

    def replay(self):
        if self.buffer.current_size < self.batch_size:
            return

        states, actions, rewards, next_states, dones = self.buffer.sample(self.batch_size)
        q_values_current = self.q_network.predict(states)
        q_values_next = self.target_network.predict(next_states)

        targets = q_values_current.copy()
        batch_indices = np.arange(self.batch_size, dtype=np.int32)
        targets[batch_indices, actions] = rewards + self.gamma * np.amax(q_values_next, axis=1) * (1 - dones)

        self.q_network.train_on_batch(states, targets)

    def update_epsilon(self):
        self.epsilon = max(self.epsilon_final, self.epsilon * self.epsilon_decay)

    def save_rewards_data(self, total_rewards, cumulative_rewards, mean_rewards):
        data = {
            "Episode": np.arange(len(total_rewards)),
            "Total Reward": total_rewards,
            "Cumulative Reward": cumulative_rewards,
            "Mean Reward": mean_rewards
        }

        df = pd.DataFrame(data)
        df.to_csv("dqn_training_rewards.csv", index=False)

    def save_model(self, model_path):
        self.q_network.save(model_path)
```

```
    def load_model(self, model_path):
        self.q_network = keras.models.load_model(model_path)
        self.update_target_network()

def plot_rewards(total_rewards, cumulative_rewards, mean_rewards, title, filename):
    fig, axs = plt.subplots(3, 1, figsize=(10, 7))

    axs[0].plot(total_rewards, label='Total Reward', color='blue')
    axs[0].set_xlabel('Episode')
    axs[0].set_ylabel('Total Reward')
    axs[0].set_title(f'Total Reward per Episode ({title})')
    axs[0].legend()
    axs[0].grid(True)
    axs[0].annotate(f'Last value: {total_rewards[-1]}', xy=(len(total_rewards)-1, total_rewards[-1]),
                    xytext=(len(total_rewards)-1, total_rewards[-1]), textcoords='data',
                    arrowprops=dict(arrowstyle='->', color='blue'))

    axs[1].plot(cumulative_rewards, label='Cumulative Reward', color='green')
    axs[1].set_xlabel('Episode')
    axs[1].set_ylabel('Cumulative Reward')
    axs[1].set_title(f'Cumulative Reward per Episode ({title})')
    axs[1].legend()
    axs[1].grid(True)
    axs[1].annotate(f'Last value: {cumulative_rewards[-1]}', xy=(len(cumulative_rewards)-1, cumulative_rewards[-1]),
                    xytext=(len(cumulative_rewards)-1, cumulative_rewards[-1]), textcoords='data',
                    arrowprops=dict(arrowstyle='->', color='green'))

    axs[2].plot(mean_rewards, label='Mean Reward', color='red')
    axs[2].set_xlabel('Episode')
    axs[2].set_ylabel('Mean Reward')
    axs[2].set_title(f'Mean Reward per Episode ({title})')
    axs[2].legend()
    axs[2].grid(True)
    axs[2].annotate(f'Last value: {mean_rewards[-1]}', xy=(len(mean_rewards)-1, mean_rewards[-1]),
                    xytext=(len(mean_rewards)-1, mean_rewards[-1]), textcoords='data',
                    arrowprops=dict(arrowstyle='->', color='red'))

    plt.tight_layout()
    plt.savefig(filename)
    plt.show()
```

کلاس DQNAgent برای پیاده‌سازی DQN استفاده می‌شود. پس از تعیین پارامترهای اولیه و شبکه عصبی، عامل در یک محیط آموزش داده می‌شود و نتایج آموزش ذخیره و رسم می‌شوند. متد ها و اتربیوت هایی داره که در زیر به اختصار بیان شدند و در شکل های فوق هم قابل مشاهده اند.

__init__ : تعریف و مقداردهی متغیرهای مورد نیاز برای یادگیری. ایجاد حافظه بازپخش و دو شبکه عصبی Q و هدف. به‌روزرسانی اولیه شبکه هدف.

متد _build_model: ساخت مدل شبکه عصبی با استفاده از Keras. تعریف لایه‌های شبکه و کامپایل آن.

متد update_target_network: به‌روزرسانی وزن‌های شبکه هدف با کپی کردن وزن‌های شبکه Q.

متد select_action: انتخاب عمل بر اساس سیاست ϵ-greedy. انتخاب تصادفی عمل یا بهترین عمل بر اساس شبکه Q.

متد train: آموزش مدل با اجرای حلقه آموزشی برای تعداد مشخص اپیزود. ذخیره و به‌روزرسانی تجربیات در حافظه. فراخوانی متد replay برای به‌روزرسانی شبکه Q. به‌روزرسانی ϵ و شبکه هدف . در اخر هم ذخیره و رسم پاداش‌های آموزشی.

متد replay: به‌روزرسانی وزن‌های شبکه Q بر اساس تجربیات ذخیره شده. انتخاب تصادفی تجربیات از حافظه و آموزش شبکه Q با استفاده از داده‌های منتخب.

متد update_epsilon: به‌روزرسانی مقدار ϵ با کاهش آن به نرخ کاهش مشخص تا مقدار نهایی.

متد save_rewards_data: ذخیره داده‌های پاداش آموزشی در فایل CSV.

متد save_model: ذخیره مدل شبکه عصبی به صورت فایل.

متد load_model: بارگذاری مدل ذخیره شده و به‌روزرسانی شبکه هدف.

و همچنین تابع plot_rewards: رسم نمودار پاداش‌های کل، تجمعی و میانگین به ازای هر اپیزود. (این تابع خارج از کلاس است.)

حال مقدار دهی های اولیه را انجام میدهیم:

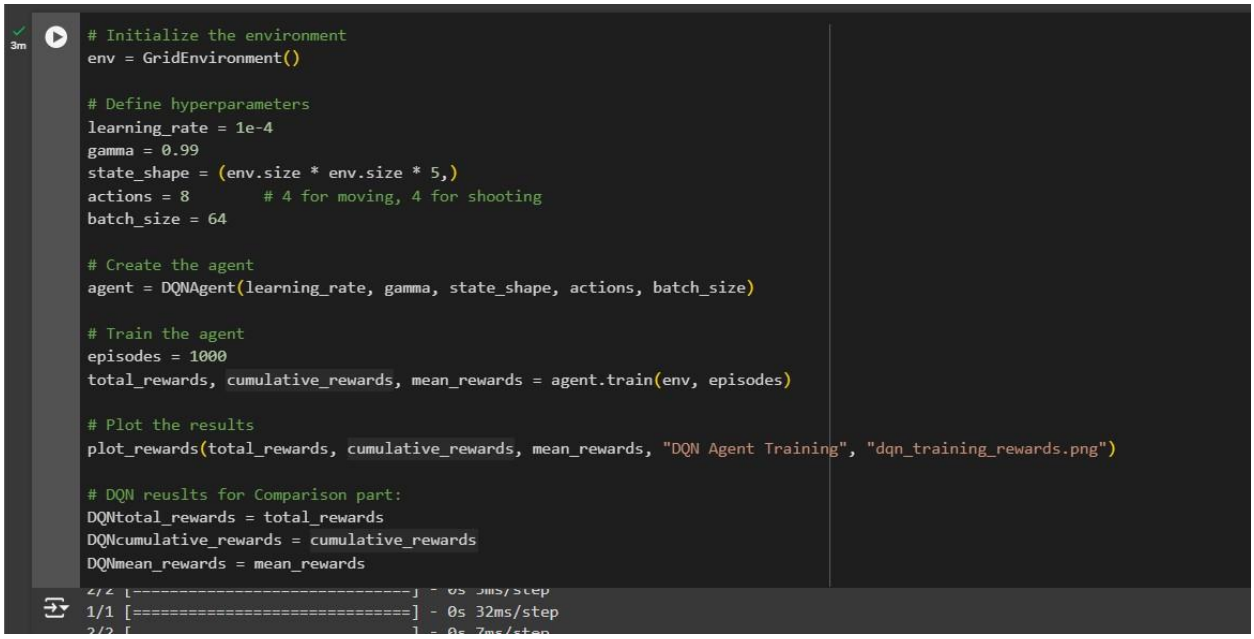

کد فوق با استفاده از یک محیط به نام GridEnvironment شروع می‌شود که به عنوان محیط آموزشی برای الگوریتم DQNعمل می‌کند. سپس، هایپرپارامترهای مختلفی اعمال می‌شوند که شامل نرخ یادگیری(learning_rate) ، ضریب کاهش پاداش(gamma) ، شکل حالت(state_shape) ، تعداد اقدامات (actions) و اندازه بچ (batch_size) می‌باشند.

یک عامل (agent) با استفاده از کلاس DQNAgent و هایپرپارامترهای مشخص شده ایجاد می‌شود. سپس، این عامل برای ۱۰۰۰ اپیزود آموزش داده می‌شود. در طی این اپیزودها، پاداش‌های کل(total rewards) ، پاداش‌های تجمعی (cumulative rewards)و میانگین پاداش‌ها (mean rewards) برای هر اپیزود ذخیره و محاسبه می‌شوند.

در نهایت، نتایج آموزش به صورت نمودارها رسم می‌شوند تا بتوانیم عملکرد الگوریتم را به طور بصری بررسی کنیم. همچنین، پاداش‌های به دست آمده نیز برای مقایسه و تحلیل بیشتر ذخیره می‌شوند.

این فرآیند به طور خلاصه به منظور آموزش و ارزیابی عملکرد الگوریتم DQN با استفاده از یک محیط مصنوعی انجام می‌شود و نتایج نهایی از طریق نمودارها و آمارهای مربوطه مورد بررسی قرار می‌گیرند.

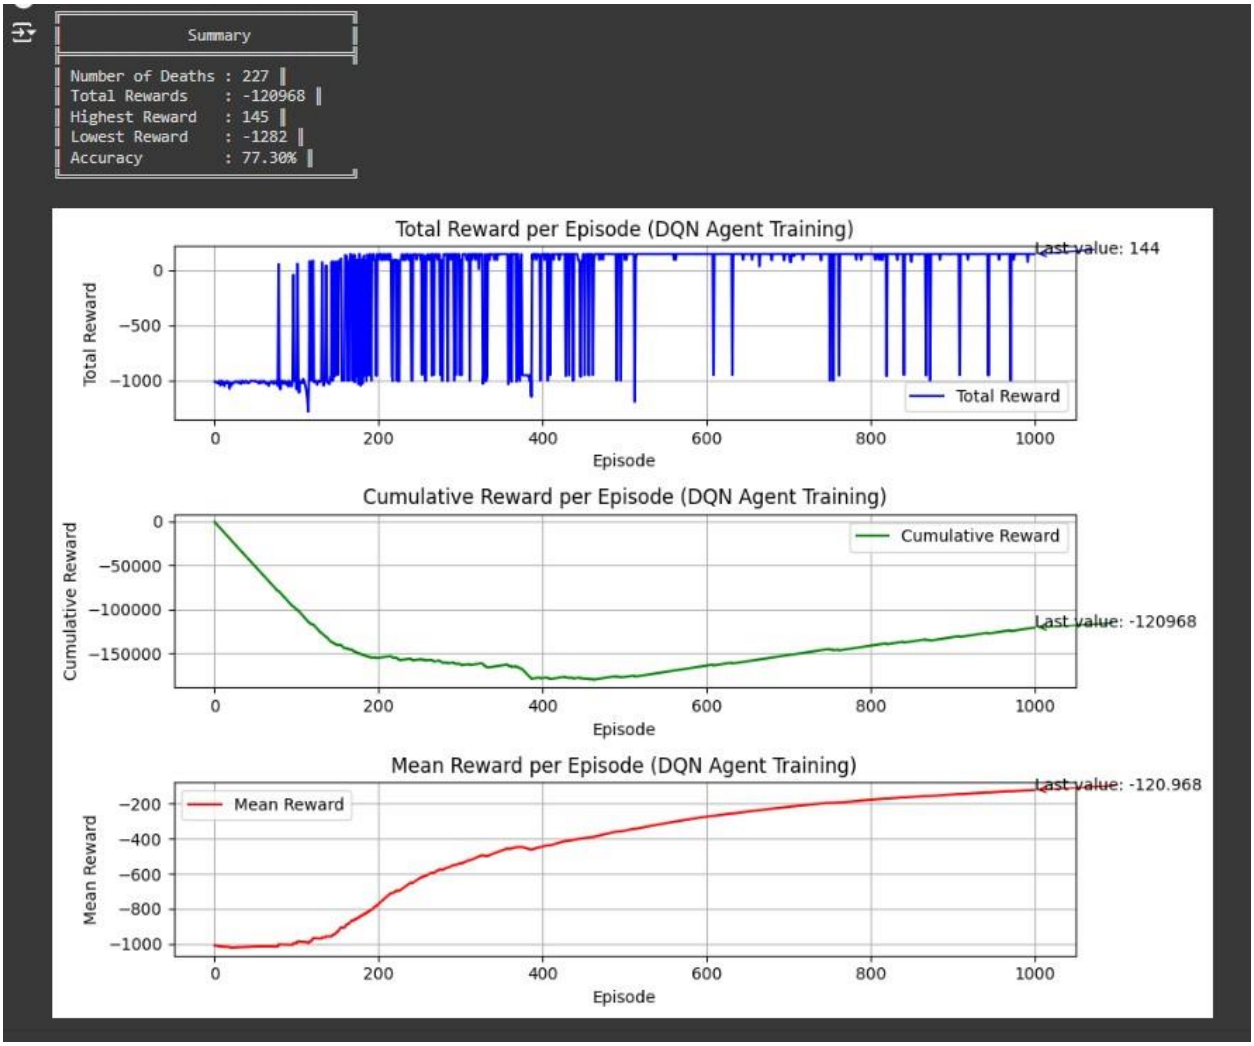

در طول آموزش به مدت ۱۰۰۰ اپیزود، عامل DQN حدود ۲۲۷ بار کشته شده است که این عملکرد بهتری نسبت به الگوریتم Q-learning دارد.

مشابه الگوریتمQ-learning ، عامل DQN به بهینه‌ترین سیاست دست یافته است و حداکثر امتیاز ممکن یعنی ۱۴۵ را کسب کرده است.

در این آزمایش، در برخی از مواقع همگرایی در الگوریتم DQN حاصل نشده است. برای مثال، حتی بعد از ۵۰۰ اپیزود، عامل همچنان پاداش‌های منفی دریافت کرده و کشته شده است. برای بررسی همگرایی، می‌توان این مدل را برای تعداد اپیزودهای بیشتری اجرا کرد.

علاوه بر این، مشخص شده است که عامل به طور قطع کشته نشده است و در بسیاری از موارد، در محیط به شدت فعال بوده است. اما، به دلیل حرکات مکرر و دریافت پاداش‌های منفی، نمی‌توان به وضوح تعیین کرد که آیا واقعاً کشته شده یا خیر.

ایده‌آل است که نتایج نهایی هر اپیزود را به‌طور جداگانه بررسی کنیم تا بتوانیم به نتیجه‌ای قطعی‌تر درباره عملکرد عامل برسیم.

به دلیل زمان طولانی اجرای الگوریتم و محدودیت‌های زمانی، به این نتایج بسنده می‌کنیم. با این حال، الگوریتم DQN همچنان دارای پتانسیل بهبود است، به‌ویژه با کاهش نرخ کاوش و تنظیم نرخ یادگیری برای جلوگیری از گیر افتادن در مینیمم‌های محلی و تعیین تعداد حرکات معقول در هر اپیزود.

در مجموع، نتایج نشان می‌دهد که الگوریتم DQN نسبت به Q-learning عملکرد بهتری داشته و سریع‌تر به صعود در امتیازها دست یافته است، اگرچه همگرایی آن کار آسانی نیست و نیازمند بررسی و تنظیمات دقیق‌تری است و زمان اجرای بیشتری دارد.

بخش ب

دو مدل را با یکدیگر مقایسه می کنیم و از کد زیر استفاده می کنیم.

```python
def plot_rewards(q_learning_rewards, q_learning_cumulative, q_learning_mean, dqn_rewards, dqn_cumulative, dqn_mean, title, filename):
    fig, axs = plt.subplots(3, 1, figsize=(10, 7))

    axs[0].plot(q_learning_rewards, label='Q-Learning Total Reward', color='blue')
    axs[0].plot(dqn_rewards, label='DQN Total Reward', color='green')
    axs[0].set_xlabel('Episode')
    axs[0].set_ylabel('Total Reward')
    axs[0].set_title(f'Total Reward per Episode ({title})')
    axs[0].legend()
    axs[0].grid(True)

    axs[1].plot(q_learning_cumulative, label='Q-Learning Cumulative Reward', color='red')
    axs[1].plot(dqn_cumulative, label='DQN Cumulative Reward', color='purple')
    axs[1].set_xlabel('Episode')
    axs[1].set_ylabel('Cumulative Reward')
    axs[1].set_title(f'Cumulative Reward per Episode ({title})')
    axs[1].legend()
    axs[1].grid(True)

    axs[2].plot(q_learning_mean, label='Q-Learning Mean Reward', color='green')
    axs[2].plot(dqn_mean, label='DQN Mean Reward', color='brown')
    axs[2].set_xlabel('Episode')
    axs[2].set_ylabel('Mean Reward')
    axs[2].set_title(f'Mean Reward per Episode ({title})')
    axs[2].legend()
    axs[2].grid(True)

    plt.tight_layout()
    plt.savefig(filename)
    plt.show()

# Plot the results for comparison
plot_rewards(Qtotal_rewards, Qcumulative_rewards, Qmean_rewards,
             DQNtotal_rewards, DQNcumulative_rewards, DQNmean_rewards,
             "Q-Learning vs DQN Training", "qlearning_vs_dqn_training_rewards.png")
```

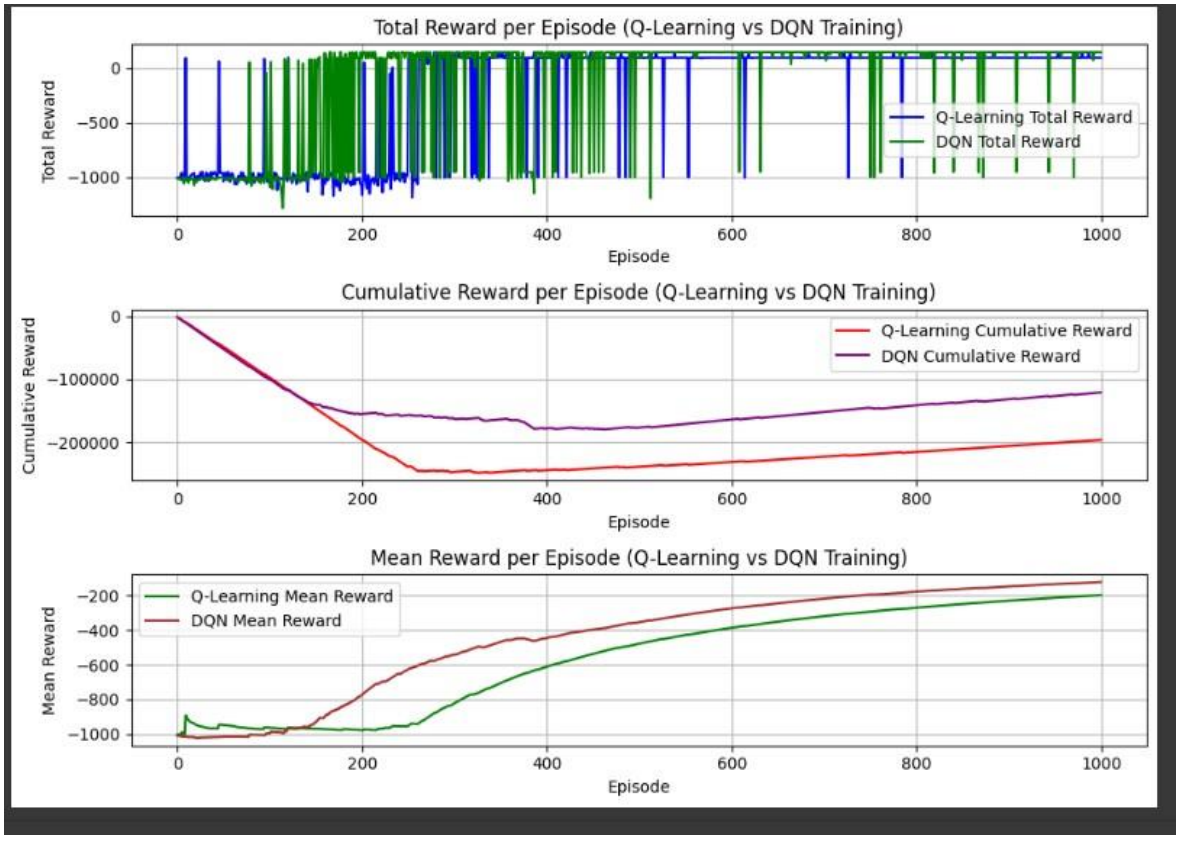

نمودارهای ارائه شده اطلاعات مهمی درباره عملکرد الگوریتم‌های Q-Learning و DQN فراهم می‌کنند. سه نمودار بدست امد و به تحلیل آن ها می پردازیم :

۱. **پاداش کل در هر اپیزود:**

- Q-Learning: در ابتدا با جوایز منفی و نوسانات زیاد مواجه است تا حدود ۳۵۰ اپیزود. بعد از آن، پاداش‌ها به تدریج مثبت می‌شوند و نوسانات کاهش می‌یابد.
- DQN: نوسانات کمتری در اوایل آموزش دارد و از حدود اپیزود ۱۷۰ پاداش‌های مثبت و پایدارتر می‌شود. این نشان‌دهنده یادگیری سریع‌تر سیاست‌های بهینه است.

۲. **پاداش تجمعی:**

- Q-Learning: در مراحل اولیه به سرعت کاهش می‌یابد و تا حدود اپیزود ۳۵۰ به تدریج افزایش می‌یابد اما همچنان از DQN پایین‌تر است.
- DQN: در اوایل آموزش کاهش کمتری دارد و از اپیزود ۱۵۰ به بعد به سرعت افزایش می‌یابد و مثبت می‌شود. این الگوریتم در مراحل اولیه عملکرد بهتری دار..

۳. ***میانگین پاداش در هر اپیزود:***

- Q-Learning: در ابتدا میانگین پاداش بسیار پایین و منفی است و به تدریج از اپیزود ۳۰۰ به بعد افزایش می‌یابد، اما هنوز از DQN پایین‌تر است.
- DQN: میانگین پاداش در مراحل اولیه پایین است اما از حدود اپیزود ۱۰۰ به بعد به طور مداوم مثبت می‌شود و به ۱۴۵ نزدیک می‌شود، در حالی که Q-Learning به ۹۵ همگرا می‌شود.

در مجموع، DQN نسبت به Q-Learning با سرعت بیشتری به سیاست‌های بهینه دست می‌یابد، پاداش‌های منفی کمتری دارد و عملکرد بهتری در مراحل اولیه آموزش نشان می‌دهد .با استفاده از شبکه‌های عصبی عمیق و حافظه بازپخش، سیاست‌های بهینه را سریع‌تر و پایدارتر یاد می‌گیرد و برای مسائل پیچیده مناسب‌تر است.

بخش ج

تاثیر این نرخ را در هر دو الگوریتم با دقت بررسی می کنیم.

تاثیر نرخ اکتشاف ϵ بر فرآیند یادگیری مدلQ-Learning

نرخ اکتشاف:ϵ

- یکی از پارامترهای کلیدی در Q-Learning است.
- در ابتدای یادگیری مقدار ϵ برابر با ۱,۰ است و با هر اپیزود کاهش می‌یابد (ضریب کاهش ۰,۹۹۵).
- ابتدا عامل بیشتر به کاوش محیط می‌پردازد و سپس به بهره‌برداری از سیاست‌های آموخته‌شده.

تاثیر نرخ اکتشاف بالا:

- تنوع تجربیات و جلوگیری از گیر افتادن در بهینه‌های محلی.
- نوسانات زیاد و پاداش‌های منفی.
- نیاز به زمان بیشتر برای همگرایی به سیاست بهینه.

تاثیر نرخ اکتشاف پایین:

- افزایش بهره‌برداری از سیاست‌های آموخته‌شده.
- پاداش‌های پایدارتر و مثبت‌تر.
- امکان گیر افتادن در نقاط بهینه محلی.

تنظیم بهینه:ϵ

- تعادل بین کاوش و بهره‌برداری.
- تاثیر چشمگیر بر کیفیت یادگیری و عملکرد نهایی عامل.
- در نمودار، در مراحل اولیه با نرخ ϵ بالا، پاداش‌ها نوسانات زیادی دارند و معمولاً منفی هستند. با کاهش نرخϵ ، پاداش‌ها پایدارتر و مثبت‌تر می‌شوند.

پس به طور خلاصه نرخ اکتشاف ϵ در الگوریتم Q-Learning یکی از پارامترهای کلیدی است که تعادل بین کاوش محیط و بهره‌برداری از سیاست‌های آموخته‌شده را تعیین می‌کند. در ابتدا، ϵ برابر با ۱,۰ است و به تدریج با ضریب ۰,۹۹۵ کاهش می‌یابد، تا در پایان ۱۰۰۰ اپیزود به مقدار کمی برسد. نرخ اکتشاف بالا در مراحل اولیه یادگیری به عامل کمک می‌کند تا تنوع تجربیات بیشتری کسب کند و از گیر افتادن در نقاط بهینه محلی جلوگیری کند، اما ممکن است منجر به ناپایداری و کاهش پاداش‌های کسب‌شده شود. در مقابل، نرخ اکتشاف پایین در مراحل پایانی بهره‌برداری بیشتر از سیاست‌های آموخته‌شده را

تشویق می‌کند و به همگرایی سریع‌تر به سیاست بهینه کمک می‌کند، اما ممکن است فرصت‌های کاوش محیط و کشف سیاست‌های بهتر را محدود کند. بنابراین، تنظیم بهینه نرخ اکتشاف ϵ برای تعادل مناسب بین کاوش و بهره‌برداری بسیار مهم است تا بهترین عملکرد در طول فرآیند یادگیری حاصل شود.

امتیاز های مدل برای Q learning به صورت زیر است (در بخش آ هم بیان شد.)

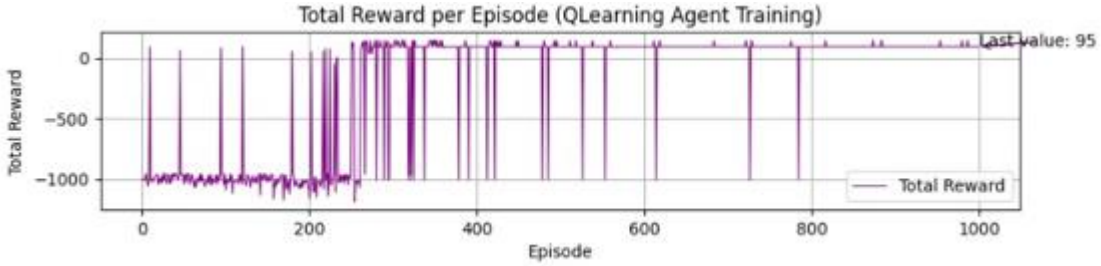

مشاهده می کنیم که در مراحل ابتدایی یادگیری با نرخ ϵ بالا، پاداش‌ها نوسان زیادی دارند و معمولاً منفی هستند زیرا عامل بیشتر به کاوش و اعمال تصادفی می‌پردازد. با کاهش نرخ ϵ، عامل به تدریج به بهره‌برداری از سیاست‌های آموخته‌شده می‌پردازد و پاداش‌ها پایدارتر و مثبت‌تر می‌شوند. در حدود اپیزود ۵۵۰، پاداش‌ها به حالت پایدار و مثبت می‌رسند که نشان‌دهنده همگرایی به سیاست بهینه است. انتخاب و تنظیم صحیح نرخ ϵ در الگوریتم Q-Learning بسیار مهم است؛ نرخ بالای اکتشاف در ابتدا برای درک بهتر محیط و جمع‌آوری تجربیات متنوع و کاهش تدریجی آن برای بهره‌برداری بیشتر از سیاست‌های یادگرفته‌شده و بهبود عملکرد یادگیری است.

تاثیر نرخ اکتشاف ϵ بر فرآیند یادگیری مدلDQN

مراحل ابتدایی:

- نرخ اکتشاف بالا منجر به نوسانات زیاد و پاداش‌های منفی.
- کمک به شناخت بهتر محیط و کسب تجربیات متنوع‌تر.

میانه فرآیند یادگیری:

- کاهش نرخ اکتشاف و افزایش بهره‌برداری از سیاست‌های آموخته‌شده.
- کاهش نوسانات پاداش و افزایش پاداش‌های مثبت.

مراحل پایانی:

- نرخ اکتشاف پایین، پاداش‌های پایدارتر و مثبت‌تر.
- بهره‌برداری بیشتر از سیاست‌های آموخته‌شده.

تنظیم مناسب نرخ اکتشاف:

- نقش مهم در بهبود فرآیند یادگیری و عملکرد نهایی عامل.
- کاهش تدریجی نرخ اکتشاف از ۱ به ۰,۰۵ طی ۶۰۰ اپیزود.

نتیجه‌گیری

- نرخ اکتشاف ϵ بالا در مراحل اولیه به عامل کمک می‌کند تا محیط را بهتر بشناسد و تجربیات متنوع‌تری کسب کند.
- کاهش تدریجی نرخ اکتشاف به بهره‌برداری بهتر از سیاست‌های آموخته‌شده و همگرایی به سیاست بهینه کمک می‌کند.
- تنظیم صحیح نرخ اکتشاف باعث بهبود عملکرد و پایداری فرآیند یادگیری می‌شود.

شکل زیر امتیاز دهی مدل DQN را در هر اپیزود نشان می دهد:

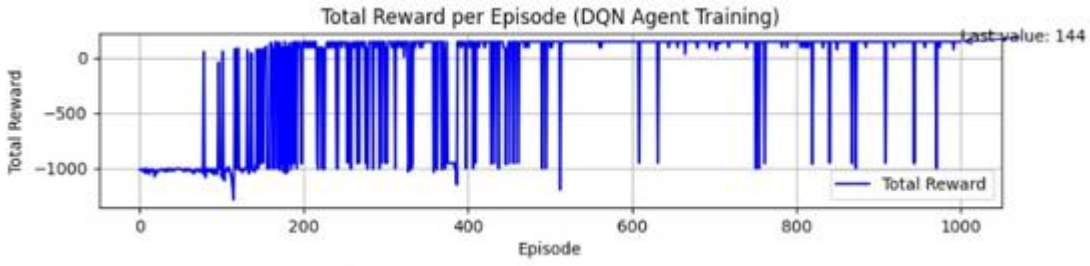

در اوایل فرآیند یادگیری در الگوریتم DQN، نرخ اکتشاف بالا است و پاداش‌ها نوسانی و عمدتاً منفی هستند. این به دلیل انجام اعمال تصادفی توسط عامل برای کاوش محیط و کسب تجربیات متنوع‌تر است. با گذشت زمان و کاهش نرخ اکتشاف، عامل شروع به بهره‌برداری از سیاست‌های آموخته شده می‌کند، که منجر به کاهش نوسانات پاداش و افزایش پاداش‌های مثبت می‌شود. این تغییر نشان‌دهنده بهبود عملکرد عامل است، هرچند که هنوز ممکن است پاداش‌های منفی نیز دیده شود و همگرایی کامل رخ نداده باشد.

در اواخر فرآیند یادگیری، نرخ اکتشاف به پایین‌ترین مقدار خود می‌رسد و پاداش‌ها پایدارتر و مثبت‌تر می‌شوند. عامل بیشتر به بهره‌برداری از سیاست‌های آموخته شده می‌پردازد، اما همچنان ممکن است به سیاست بهینه همگرا نشده باشد. با این حال، نمودار نشان می‌دهد که عملکرد عامل به تدریج بهبود می‌یابد و پاداش‌های بالاتری کسب می‌کند. به طور کلی، تنظیم مناسب و کاهش تدریجی نرخ اکتشاف نقش مهمی در بهبود فرآیند یادگیری و عملکرد نهایی عامل دارد. پس از حدود ۶۰۰ اپیزود، مقدار اپسیلون به ۰,۰۵ همگرا می‌شود و عامل از حالت اکتشاف به بهره‌برداری منتقل می‌شود. تنظیم بهتر مدل و تعریف محدودیت‌هایی برای تعداد گام‌های مجاز می‌تواند به بهبود عملکرد و همگرایی کمک کند.

بخش د

تحلیل تعداد اپیزودها برای دستیابی به عملکرد پایدار

Q-Learning:

- نیاز به حدود ۳۰۰ اپیزود برای دستیابی به عملکرد پایدار و مثبت.
- پس از ۵۲۰ اپیزود به طور کامل بازی را فراگرفته و پاداش منفی دریافت نمی‌کند.
- فرآیند یادگیری طولانی و ناپایدار است و ممکن است به سیاست بهینه نرسد.

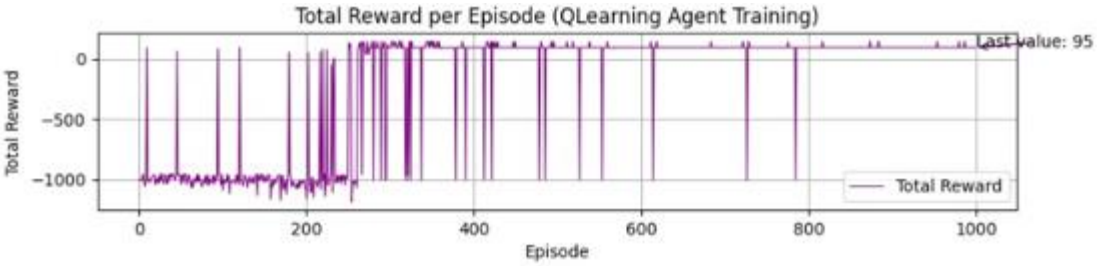

DQN:

- تنها به حدود ۱۰۰ اپیزود برای رسیدن به عملکرد پایدار و مثبت نیاز دارد.
- سریع‌تر به سیاست‌های بهینه دست می‌یابد و عملکرد پایدارتر و بهتری دارد.
- نمی‌توان دقیقاً گفت که پاداش‌های منفی به دلیل کشته شدن عامل یا حرکات بیش از حد ایجاد شده‌اند.

تحلیل کارایی مدل‌ها در دستیابی به سیاست بهینه

Q-Learning:

- نوسانات و پاداش‌های منفی در مراحل اولیه
- به تدریج به سیاست‌های بهینه نزدیک می‌شود، اما فرآیند طولانی و ناپایدار است
- ممکن است به بهترین سیاست دست نیابد

DQN:

- بهره‌گیری از شبکه‌های عصبی عمیق و حافظه بازپخش
- سیاست‌های بهینه را سریع‌تر و با ثبات بیشتری یاد می‌گیرد.
- نمودارهای پاداش تجمعی و میانگین پاداش نشان‌دهنده عملکرد برتر DQN است.

نتیجه‌گیری: دو نتیجه زیر را می توان گرفت

- **DQN**: سریع‌تر، پایدارتر و مؤثرتر از Q-Learning عمل می‌کند و گزینه بهتری برای مسائل پیچیده با فضای حالت بزرگ است.
- **Q-Learning**: فرآیند یادگیری طولانی‌تر و ناپایدارتر، با نوسانات بیشتر در مراحل اولیه.

DQNبا استفاده از تکنیک‌های پیشرفته در یادگیری تقویتی، به ویژه برای مسائل پیچیده، عملکرد بهتری نسبت به-Q Learningدارد.

بخش ه

در الگوریتمDeep Q-Networks (DQN) ، شبکه عصبی به گونه‌ای طراحی شده است که توابع Q-value را برای محیط‌های پیچیده با فضای حالت بزرگ تخمین بزند. این شبکه شامل لایه‌های مخفی و توابع فعال‌سازی است.

ساختار کلی این شبکه به صورت زیر است :

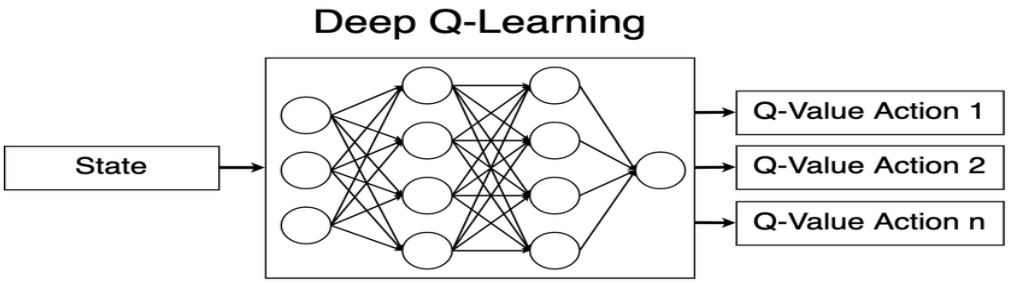

ساختار مدل:

کد پایتون برای پیاده سازی آن به صورت زیر است :

```
def _build_model(self, state_shape, num_actions):
    model = keras.Sequential([
        keras.layers.Dense(128, activation='relu', input_shape=state_shape),
        keras.layers.Dense(128, activation='relu'),
        keras.layers.Dense(num_actions, activation=None)
    ])
    model.compile(optimizer=keras.optimizers.Adam(learning_rate=self.learning_rate),
                  loss=Huber())
    return model
```

از Keras برای ساخت مدل استفاده می‌شود.

- **تابع build_model_** : دو ورودی state_shape (شکل ورودی حالت‌ها) و num_actions (تعداد اکشن‌ها) دارد.
- **لایه‌ها:**
  - **لایه اول** Dense :با ۱۲۸ نورون و تابع فعال‌سازیReLU
  - **لایه دوم** Dense :با ۱۲۸ نورون و تابع فعال‌سازیReLU
  - **لایه سوم** Dense :با تعداد نورون برابر با num_actions و خروجی خطی.

کامپایل مدل: از کد هم قابل مشاهده است که :

- **بهینه‌ساز** Adam :با نرخ یادگیری تنظیم شده
- **تابع هزینه** :هابر (Huber loss) برای کاهش تاثیر نویزهای بزرگ

دلایل انتخاب معماری:

۱. **توابع فعال‌سازی:ReLU**
   - محاسبات سریع‌تر نسبت به سیگموئید و تانژانت هایپربولیک
   - عدم مشکل اشباع و مقیاس‌پذیری بهتر

۲. **تعداد نورون‌ها:**
   - 128نورون در هر لایه مخفی تعادل مناسبی بین پیچیدگی و قابلیت‌های محاسباتی ایجاد می‌کند
   - جلوگیری از بیش‌برازش و یادگیری ویژگی‌های پیچیده

۳. **تابع هزینه هابر:**
   - ترکیب خطای مطلق و خطای مربعی
   - کاهش حساسیت به نقاط پرت و کمک به پایداری یادگیری

مزایا:

- **یادگیری ویژگی‌های پیچیده** :شبکه قادر به یادگیری و تقریب توابع Q-value پیچیده است
- **لایه‌های مخفی متعدد** :توانایی یادگیری روابط پیچیده بین وضعیت‌ها و اعمال

- **پایداری و کارایی** :استفاده از تابع Huber به بهبود پایداری و کاهش نوسانات در به‌روزرسانی وزن‌ها کمک می‌کند.

نرخ کاوش(Exploration) :

- کاهش تدریجی نرخ کاوش که به دستیابی به سیاست بهینه با امتیاز ۱۴۵ کمک کرده است.

این معماری به دلیل سادگی و کارایی بالا، یکی از معماری‌های رایج در مسائل یادگیری تقویتی پیچیده مانند بازی‌های ویدیویی و شبیه‌سازی‌های پیچیده است.